

## Muestreo en Varias Etapas

Curso de Muestreo Probabilístico en Encuestas de Hogares

Andrés Gutiérrez, Ph.D.

CEPAL - Unidad de Estadísticas Sociales

- ① Aglomeración
- ② Muestreo de conglomerados
- ③ Muestreo en varias etapas
- ④ Muestreo en dos etapas
- ⑤ Otros diseños en varias etapas

## Motivación

*En encuestas complejas, los grupos poblacionales de elementos que se forman naturalmente como barrios, municipios o escuelas pueden ser tratados como unidades de muestreo. Este tipo de esquemas de muestreo ayuda a aumentar el tamaño de muestra manteniendo el costo de la encuesta.*

Risto Lehtonen (2004)

## Bibliografía y referencias

- Kish, L. (1965) *Survey Sampling*. John Wiley and Sons.
- Cochran, W. G. (1977) *Sampling Techniques*. John Wiley and Sons.
- Särndal, et. al. (2003) *Model-assisted Survey Sampling*. Springer.
- Gutiérrez, H. A. (2016) *Estrategias de muestreo: diseño de encuestas y estimación de parámetros*. Ediciones de la U.
- Gutiérrez, H. A. (2017) *TeachingSampling. R package*.

# Aglomeración

## Características

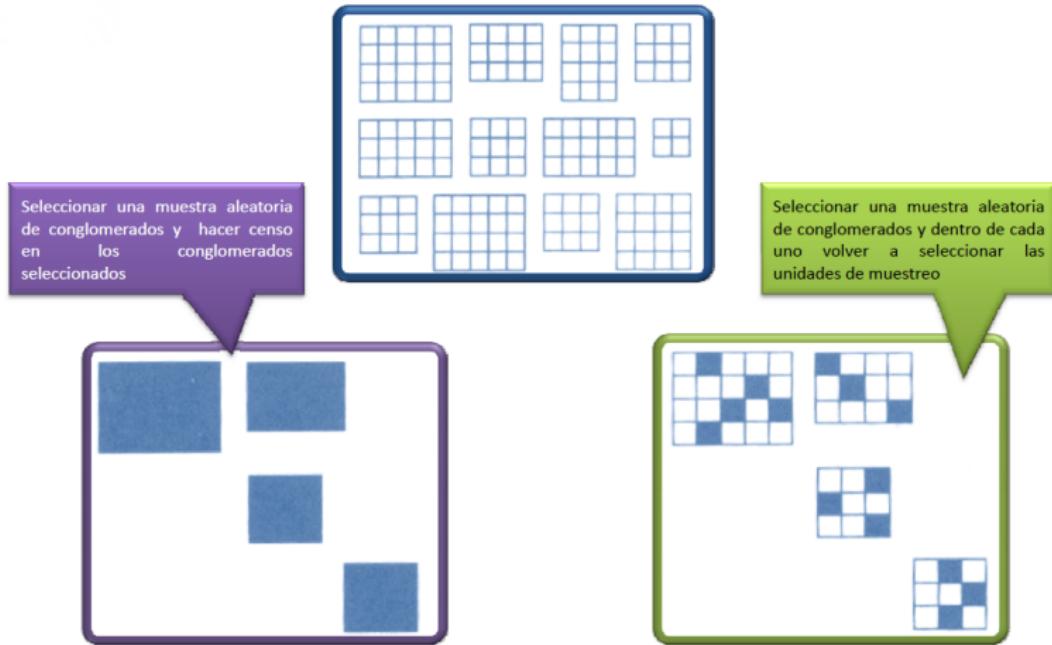


Figure 1: *Muestreo de conglomerados y en etapas*

## Características

Utilizamos muestreo por conglomerados sí:

- La construcción de un marco de muestreo de elementos es muy difícil, muy costosa o imposible de conseguir. Enumerar abejas, enumerar clientes, enlistar árboles en un sector, enlistar hogares en los barrios conglomerados (dispersión geográfica, reducción de costos).
- La población objetivo se encuentra muy dispersa (geográficamente) o aparece en agrupaciones naturales: familias, escuelas, etc.

## Características

- Los elementos individuales de una población sólo participan en la muestra si pertenecen a un conglomerado incluido en la muestra.
- El muestreo estratificado aumenta la precisión de las estimaciones, mientras que el muestreo por conglomerados tiende a disminuirla. Es un precio que se paga al no poseer un marco de muestreo definido para los elementos de la población objetivo.
- Al obtener una muestra de elementos que pertenecen a un conglomerado repetimos la información del conglomerado (dada la agrupación natural). Lo ideal es conseguir información nueva en cada individuo, por lo anterior se pierde precisión en las estimaciones.

## Muestreo de conglomerados

## Características

Suponga que la población de elementos

$$U = \{1, \dots, k, \dots, N\}.$$

se divide en  $N_I$  sub-grupos poblacionales, llamados **conglomerados** y denotados como  $U_I = \{U_1, \dots, U_{N_I}\}$ .

## Características

La población de conglomerados estará dada, sin pérdida de generalidad, por

$$U_I = \{1, \dots, N_I\}.$$

Estos definen una partición de la población en tal forma que

- ①  $U = \bigcup_{i=1}^{N_I} U_i$
- ②  $U_i \cap U_j = \emptyset$  para todo  $i \neq j$

## Características

El número de unidades  $N_i$  en el conglomerado  $i$ -ésimo se llama **tamaño del conglomerado** tal que

$$N = \sum_{i=1}^{N_I} N_i,$$

donde  $N$  es el tamaño de la población  $U$ . Con la población dividida en  $N_I$  conglomerados,

## Parámetros poblacionales

El total poblacional puede escribirse como:

$$t_y = \sum_{k \in U} y_k = \sum_{i=1}^{N_I} \sum_{k \in U_i} y_k = \sum_{i=1}^{N_I} t_{yi} \quad (1)$$

donde  $t_{yi} = \sum_{k \in U_i} y_k$  es el total del  $i$ -ésimo conglomerado.

## Parámetros poblacionales

La media poblacional puede escribirse como:

$$\bar{y}_U = \frac{\sum_{k \in U} y_k}{N} = \frac{1}{N} \sum_{i=1}^{N_I} \sum_{k \in U_i} y_k = \frac{1}{N} \sum_{i=1}^{N_I} N_i \bar{y}_i \quad (2)$$

donde  $\bar{y}_i = \frac{1}{N_i} \sum_{k \in U_i} y_k$  es la media del  $i$ -ésimo conglomerado.

## Diseño de muestreo

El esquema general del diseño de muestreo por conglomerados está definido de la siguiente forma

- ① Seleccionar una muestra probabilística  $s_I$  de conglomerados de la población  $U_I$  mediante un diseño de muestreo tal que

$$Pr(S_I = s_I) = p_I(s_I) \quad \text{para todo } s_I \in Q_I. \quad (3)$$

donde  $Q_I$  es el soporte de muestras de conglomerados.

- ② Todos y cada uno de los elementos pertenecientes a los conglomerados seleccionados son observados y medidos.

## Diseño de muestreo

En muestreo por conglomerados, se utiliza un diseño  $p_I(s_I)$  que puede ser cualquiera de los vistos anteriormente:

- **Sin reemplazo:** si todas las posibles muestras en  $Q_I$  son sin reemplazo. Muestreo aleatorio simple, Bernoulli, Sistemático, Poisson,  $\pi$ PPT o estratificado simple.
- **Con reemplazo:** si todas las posibles muestras en  $Q_I$  son con reemplazo. Muestreo aleatorio simple con reemplazo o muestreo PPT.
- **De tamaño fijo:** si todas las posibles muestras en  $Q$  tienen el mismo tamaño de muestra  $n(S_I) = n_I$ .

## La muestra

La muestra aleatoria de elementos viene caracterizada por

$$S = \bigcup_{i \in S_I} U_i \quad (4)$$

## El tamaño de muestra

El tamaño de la muestra de elementos está dado por

$$n(S) = \sum_{i \in S_l} N_i \quad (5)$$

## Ejemplo

Nuestra población ejemplo  $U$  dada por

$$U = \{\mathbf{Yves}, \mathbf{Ken}, \mathbf{Erik}, \mathbf{Sharon}, \mathbf{Leslie}\}$$

se divide en tres conglomerados de la siguiente forma

$$U_1 = \{\mathbf{Yves}, \mathbf{Ken}\}$$

el segundo conformado por

$$U_2 = \{\mathbf{Erik}, \mathbf{Sharon}\}$$

y el último conglomerado dado por

$$U_3 = \{\mathbf{Leslie}\}$$

## Ejemplo

Se tienen  $N_I = 3$  conglomerados de tamaño diferentes. De esta manera, la población de conglomerados queda definida por

$$U_I = \{U_1, U_2, U_3\}$$

## Ejemplo

Suponga que se selecciona una muestra  $s_I$  de conglomerados de tamaño  $n_I = 2$ .

```
U <- c("Yves", "Ken", "Erik", "Sharon", "Leslie")
U1 <- c("Yves", "Ken")
U2 <- c("Erik", "Sharon")
U3 <- c("Leslie")

UI <- c("U1", "U2", "U3")
```

## Ejemplo

Las posibles muestras (sin reemplazo y de tamaño fijo) de conglomerados son:

```
library(TeachingSampling)
```

```
NI <- 3
```

```
nI <- 2
```

```
QI <- Support(NI, nI, UI)
```

```
QI
```

U1	U2
U1	U3
U2	U3

## Estimador del total poblacional

El estimador de Horvitz-Thompson para el total  $t_y$  y su varianza estimada están dados por

$$\hat{t}_{y,\pi} = \sum_{i \in S_I} \frac{t_{yi}}{\pi_{li}} \quad (6)$$

$$\widehat{Var}_1(\hat{t}_{y,\pi}) = \sum_{S_I} \sum \frac{\Delta_{lij}}{\pi_{lij}} \frac{t_{yi}}{\pi_{li}} \frac{t_{yj}}{\pi_{lj}} \quad (7)$$

respectivamente, con  $\Delta_{lij} = \pi_{lij} - \pi_{li}\pi_{lj}$  y  $t_{yi}$  el total del  $i$ -ésimo conglomerado seleccionado.

## Comentarios

- La eficiencia de la estrategia de muestreo toma su máximo valor cuando los valores  $\frac{t_{yi}}{\pi_{Ii}}$  son constantes para todo  $i = 1, \dots, N_I$ .
- Cuando el diseño por conglomerados asigna probabilidades de inclusión idénticas a cada conglomerado, la estrategia pierde eficiencia, a menos que el comportamiento de los totales de cada conglomerado sea similar.

## Comentarios

- Es preferible escoger diseños de muestreo que asignen probabilidades de inclusión proporcionales al tamaño del conglomerado.
- Para esto se debería disponer de información auxiliar continua disponible para toda la población  $U_I$  que estuviera bien correlacionada con los totales de la característica de interés en cada conglomerado  $t_{yi}$ .
- Si  $t_{xi}$  es el total de la información auxiliar en el  $i$ -ésimo conglomerado, la correlación entre  $t_{xi}$  y  $t_{yi}$  debería ser bastante fuerte.

## Comentarios

- Si la selección de los conglomerados se hace con reemplazo, haciendo uso de un diseño de muestreo PPT, es posible utilizar los principios del estimador de Hansen-Hurwitz para completar la estrategia de muestreo.
- En caso de conocer los tamaños  $N_i$  de cada cluster  $i = 1, \dots, N_I$ , estos mismos pueden ser utilizados como medidas de tamaño para desarrollar un plan de muestreo con probabilidades proporcionales.

## Estimador del total poblacional

El estimador de Hansen-Hurwitz para el total  $t_y$  y su varianza estimada están dados por

$$\hat{t}_{y,p} = \frac{1}{m_I} \sum_{v=1}^{m_I} \frac{t_{yi_v}}{p_{li_v}} \quad (8)$$

$$\widehat{Var}(\hat{t}_{y,p}) = \frac{1}{m_I(m_I - 1)} \sum_{v=1}^{m_I} \left( \frac{t_{yi_v}}{p_{li_v}} - \hat{t}_{y,p} \right)^2 \quad (9)$$

respectivamente, en donde  $p_{li} = \frac{t_{xi}}{t_x}$ .

## Muestreo aleatorio simple de conglomerados

- La muestra  $s_I$  de  $n_I$  conglomerados es seleccionada mediante un diseño de muestreo aleatorio simple sin reemplazo.
- Este diseño de muestreo asume que el comportamiento del total de la característica de interés es constante en cada uno de los conglomerados.

## Muestreo aleatorio simple de conglomerados

- En la práctica esta situación se presenta en muy pocas ocasiones, es por esto que este diseño pierde precisión, en la mayoría de ocasiones, ante el muestreo aleatorio simple.
- Para que este diseño de muestreo sea más eficiente el valor promedio de la característica de interés en cada cluster  $\bar{y}_{U_i}$  debería ser proporcional a  $\frac{c}{N_i}$ .

## Tamaño de muestra

El tamaño de la muestra de elementos  $s$  es aleatorio y su esperanza está dada por

$$E(n(S)) = N \frac{n_I}{N_I} \quad (10)$$

## Muestreo sistemático

- Nótese que el diseño de muestreo sistemático en un caso especial del muestreo aleatorio de conglomerados cuando se selecciona una muestra  $s_I$  de tamaño igual a  $n_I = 1$ .
- Al igual que en muestreo sistemático no se tiene un estimador de la varianza cuando se selecciona sólo un conglomerado.

## Práctica en R

```
library(TeachingSampling)
library(dplyr)
data("BigCity")

Hogares <- BigCity %>% group_by(HHID) %>%
  summarise(Estrato = unique(Zone),
            UPM = unique(PSU),
            Personas = n(),
            Ingreso = sum(Income),
            Gasto = sum(Expenditure),
            Pobreza = unique(Poverty))
```

## Práctica en R

```
attach(Hogares)

UI <- levels(as.factor(Hogares$UPM))
NI <- length(UI)
nI <- 100
```

## Práctica en R

```
samI <- S.SI(NI, nI)
muestra <- UI[samI]
muestra
```

```
## [1] "PSU0026" "PSU0033" "PSU0043" "PSU0047" "PSU0061" "PSU0068" "PSU0070"
## [8] "PSU0082" "PSU0123" "PSU0142" "PSU0159" "PSU0173" "PSU0174" "PSU0207"
## [15] "PSU0213" "PSU0222" "PSU0243" "PSU0251" "PSU0289" "PSU0298" "PSU0302"
## [22] "PSU0303" "PSU0338" "PSU0385" "PSU0387" "PSU0402" "PSU0413" "PSU0415"
## [29] "PSU0455" "PSU0463" "PSU0465" "PSU0488" "PSU0496" "PSU0502" "PSU0504"
## [36] "PSU0529" "PSU0530" "PSU0544" "PSU0545" "PSU0562" "PSU0573" "PSU0618"
## [43] "PSU0620" "PSU0629" "PSU0631" "PSU0639" "PSU0669" "PSU0676" "PSU0679"
## [50] "PSU0728" "PSU0731" "PSU0762" "PSU0773" "PSU0798" "PSU0806" "PSU0821"
## [57] "PSU0851" "PSU0892" "PSU0901" "PSU0946" "PSU0999" "PSU1001" "PSU1013"
## [64] "PSU1046" "PSU1061" "PSU1070" "PSU1099" "PSU1147" "PSU1157" "PSU1168"
## [71] "PSU1171" "PSU1173" "PSU1212" "PSU1214" "PSU1249" "PSU1254" "PSU1258"
## [78] "PSU1268" "PSU1299" "PSU1328" "PSU1370" "PSU1379" "PSU1383" "PSU1404"
## [85] "PSU1409" "PSU1411" "PSU1426" "PSU1441" "PSU1462" "PSU1477" "PSU1504"
## [92] "PSU1525" "PSU1538" "PSU1574" "PSU1609" "PSU1639" "PSU1643" "PSU1645"
## [99] "PSU1657" "PSU1658"
```

## Práctica en R

```
CityI <- Hogares[which(Hogares$UPM %in% muestra),]  
attach(CityI)  
head(CityI)
```

HHID	Estrato	UPM	Personas	Ingreso	Gasto	Pobreza
idHH00355	Rural	PSU0026	4	4283	1796	NotPoor
idHH00356	Rural	PSU0026	2	1782	390	NotPoor
idHH00357	Rural	PSU0026	4	895	593	Relative
idHH00358	Rural	PSU0026	4	4190	2094	NotPoor
idHH00359	Rural	PSU0026	6	1358	2055	Relative
idHH00360	Rural	PSU0026	4	2525	945	NotPoor

# Práctica en R

```
Area <- as.factor(CityI$UPM)
estimaI <- data.frame(CityI$Personas, CityI$Ingreso, CityI$Gasto)
head(estimaI)
```

CityI.Personas	CityI.Ingreso	CityI.Gasto
4	4283	1796
2	1782	390
4	895	593
4	4190	2094
6	1358	2055
4	2525	945

## Práctica en R

E.1SI(NI, nI, estimai, Area)

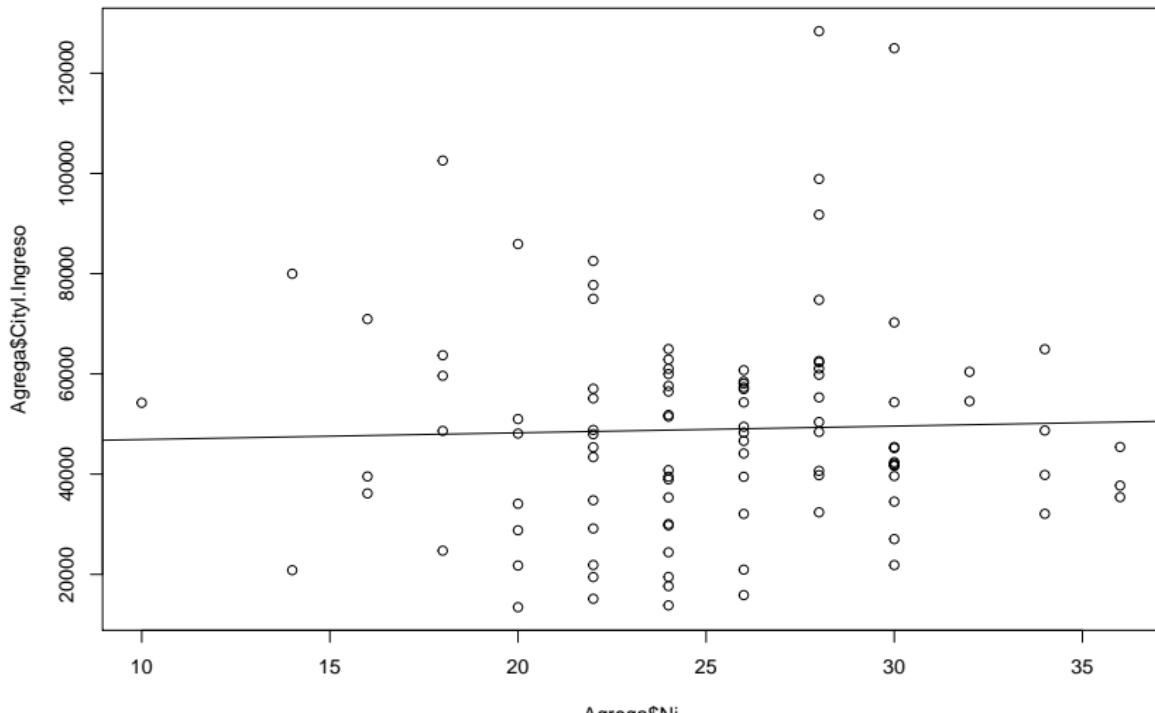
	N	Cityl.Personas	Cityl.Ingreso	Cityl.Gasto
Estimation	41766.4	152389.1	81420759.7	53805486.3
Standard Error	814.4	3691.1	3492922.8	2362556.2
CVE	1.9	2.4	4.3	4.4
DEFF	Inf	5.6	2.7	3.6

## Práctica en R

- Es claro que los resultados de esta estrategia de muestreo no son satisfactorios.
- La explicación de la deficiencia de esta estrategia es inmediata al analizar el comportamiento estructural de los totales en los conglomerados.

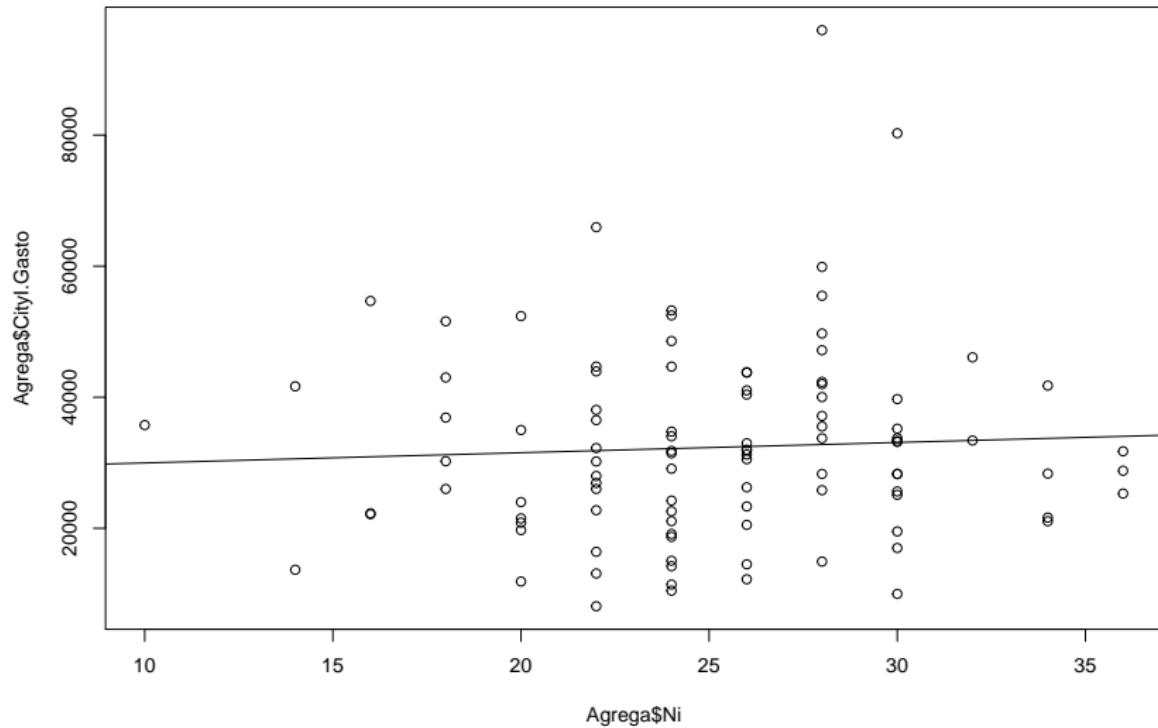
## Práctica en R

```
Agrega <- as.data.frame(T.SIC(estimaI, Area))
plot(Agrega$Ni, Agrega$CityI.Ingreso)
abline(lm(Agrega$CityI.Ingreso ~ Agrega$Ni))
```



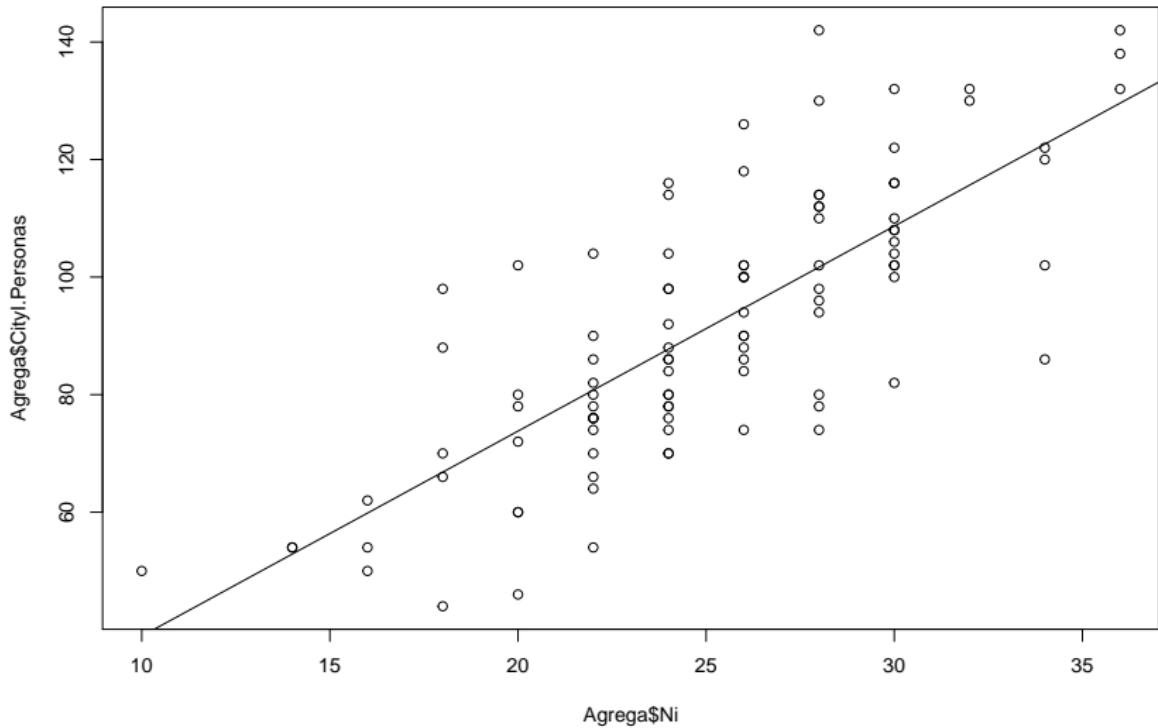
## Práctica en R

```
plot(Agrega$Ni, Agrega$CityI.Gasto)
abline(lm(Agrega$CityI.Gasto ~ Agrega$Ni))
```



## Práctica en R

```
plot(Agrega$Ni, Agrega$CityI.Personas)
abline(lm(Agrega$CityI.Personas ~ Agrega$Ni))
```



## Muestreo en varias etapas

## Características

- Anteriormente se utilizó la agrupación natural de los elementos en la población para ahorrar costes financieros y logísticos al planear una estrategia de muestreo por conglomerados.
- El ahorro en términos operativos se ve reflejado en un alto precio por pagar con respecto a la eficiencia estadística de la estrategia.
- Una posible solución para disminuir la varianza es aumentar el tamaño de muestra de conglomerados, solución que aumentaría los costos operativos.

## Características

- Para mantener un equilibrio entre los costos financieros y las bondades de la estrategia de muestreo es posible aprovechar la homogeneidad dentro de los conglomerados.
- No vamos a realizar un censo dentro de cada conglomerado seleccionado sino a seleccionar una sub-muestra dentro de cada uno.

## Características

- Como el comportamiento estructural de la característica de interés al interior de los conglomerados es homogéneo, entonces una estimación del total del conglomerado tendría una varianza pequeña.
- Como no se tienen acceso a un marco de muestreo de elementos, se debe realizar un empadronamiento para levantar un marco de muestreo de elementos en cada uno de los conglomerados seleccionados.

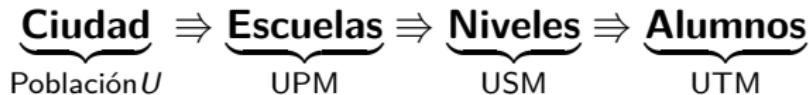
## Características

El principio básico del muestreo en varias etapas se puede definir como el proceso jerárquico que realiza / veces los siguientes pasos:

- ① Construcción de / marcos de muestreo de unidades (conglomerados en las primeras / – 1 etapas del diseño muestral y de elementos en la última etapa).
- ② Aplicación de un diseño muestral y selección de la muestras (o sub-muestras) de cada marco de muestreo.

## Unidades de muestreo

Es interesante observar cómo la población, en el estado de la naturaleza, se subdivide gracias al comportamiento “jerárquico” de las poblaciones.



## Unidades de muestreo

- ① **Unidad Primaria de Muestreo o UPM** es la primera subdivisión en conglomerados de la población original.
- ② **Unidad Secundaria de Muestreo o USM** es la sub-subdivisión de las unidades primarias.
- ③ La **Unidad Terciaria de Muestreo o UTM** corresponde a los elementos de la población objetivo, que en el caso anterior corresponde a los alumnos de la ciudad.

## Unidades de muestreo

- No siempre las unidades finales de muestreo son elementos.
- Es posible planear un diseño en dos etapas de conglomerados, refiriéndose a que la unidad secundaria de muestreo son conglomerados.
- También es posible aplicar un diseño en cuatro etapas de elementos, en donde las unidades finales de muestreo sean elementos

## Unidades de muestreo

Considere el siguiente caso:



## Supuestos

El principio básico de una estrategia de muestreo en varias etapas es construir estimaciones desde abajo hasta arriba.

- ① **Invariancia:** sugiere que la probabilidad de selección de una muestra de unidades de muestreo (conglomerados o elementos) no depende del diseño de muestreo de la anterior etapa.
- ② **Independencia:** interpretado como que el sub-muestreo de cualquier unidad de muestreo se lleva a cabo de manera independiente con las otras unidades de muestreo, en la misma etapa o en etapas superiores o inferiores.

## Muestreo en dos etapas

## Características

- ① Este diseño de muestreo estima el total de cada cluster  $t_i$  mediante una sub-muestra dentro de los conglomerados seleccionados de la población.
- ② En la estimación de los parámetros de interés se encuentran dos fuentes de variabilidad en cada etapa.
  - Existe variabilidad debido a la selección de las unidades primarias de muestreo.
  - También existe variabilidad debido a la selección de una muestra de elementos, unidades secundarias de muestro en los conglomerados seleccionados.

## Características

- Una muestra  $s_I$  de unidades primarias de muestreo es seleccionada de  $U_I$  de acuerdo a un diseño de muestreo  $p_I(s_I)$ .
- Nótese que  $S_I$  representa la muestra aleatoria de conglomerados tal que  $Pr(S_I = s_I) = p_I(s_I)$ .

## Características

- Para cada conglomerado  $U_i$   $i = 1, \dots, N_I$  seleccionado en la muestra  $s_I$ , se selecciona una muestra  $s_i$  de elementos de acuerdo a un diseño de muestreo  $p_i(s_i)$ .
- Nótese que  $S_i$  representa la muestra aleatoria de elementos tal que  $Pr(S_i = s_i) = p_i(s_i)$ .

## Estimador del total poblacional

El estimador de Horvitz-Thompson es insesgado para el total poblacional y toma la forma

$$\hat{t}_{y,\pi} = \sum_{i \in S_I} \sum_{k \in S_i} \frac{y_k}{\pi_{I|i} \pi_{k|i}} = \sum_{i \in S_I} \frac{\hat{t}_{yi,\pi}}{\pi_{I|i}} \quad (11)$$

donde

$$\hat{t}_{yi,\pi} = \sum_{k \in S_i} \frac{y_k}{\pi_{k|i}}$$

## Estimador de la varianza total poblacional

La varianza estimada del estimador de Horvitz-Thompson es

$$\widehat{Var}_{BI}(\hat{t}_{y,\pi}) = \underbrace{\sum_{S_I} \sum_{ij} \frac{\Delta_{lij}}{\pi_{lij}} \frac{\hat{t}_{yi,\pi}}{\pi_{li}} \frac{\hat{t}_{yj,\pi}}{\pi_{lj}}}_{\widehat{Var}(UPM)} + \underbrace{\sum_{i \in S_I} \frac{\widehat{Var}(\hat{t}_{yi,\pi})}{\pi_{li}}}_{\widehat{Var}(USM)} \quad (12)$$

donde

$$\widehat{Var}(\hat{t}_i) = \sum_{S_i} \sum_{kl|i} \frac{\Delta_{kl|i}}{\pi_{kl|i}} \frac{y_k}{\pi_{k|i}} \frac{y_l}{\pi_{l|i}} \quad (13)$$

## Diseño de muestreo MAS-MAS

- En el muestreo aleatorio simple de conglomerados se medían todos y cada una de los elementos pertenecientes a los conglomerados seleccionados en la muestra  $s_I$ .
- En la mayoría de situaciones, los conglomerados tienden a ser muy similares en el comportamiento estructural de la característica de interés.
- Se consideraría un desperdicio de recursos económicos y logísticos la incorporación de elementos que no traen consigo nueva información.

## Diseño de muestreo MAS-MAS

- Se supone que la población está dividida en  $N_I$  unidades primarias de muestreo, de las cuales se selecciona una muestra  $s_I$  de  $n_I$  unidades mediante un diseño de muestreo aleatorio simple.
- El sub-muestreo dentro de cada unidad primaria seleccionada es también aleatorio simple.
- Para cada unidad primaria de muestreo seleccionada  $i \in s_{Ih}$  de tamaño  $N_i$  se selecciona una muestra  $s_i$  de elementos de tamaño  $n_i$ .

## Probabilidades de inclusión

- Cuando el diseño de muestreo es aleatorio simple en las dos etapas, se tienen las siguientes probabilidades de inclusión de primer y segundo orden

$$\pi_{Ii} = \frac{n_I}{N_I} \quad (14)$$

- La probabilidad de inclusión de un elemento o unidad secundaria de muestreo perteneciente a la  $i$ -ésima unidad primaria de muestreo  $i \in U_I$  está dado por

$$\pi_k = \frac{n_I}{N_I} \frac{n_i}{N_i} \quad (15)$$

## Estimación de subtotales

Como no se miden todos los elementos de las unidades primarias seleccionadas, se deben estimar los totales  $t_{yi}$  mediante la siguiente expresión

$$\hat{t}_{yi,\pi} = \frac{N_i}{n_i} \sum_{k \in S_i} y_k = N_i \bar{y}_{U_i} \quad (16)$$

## Estimador del total poblacional

El estimador de Horvitz-Thompson toma la forma

$$\hat{t}_{y,\pi} = \frac{N_I}{n_I} \sum_{i \in S_I} \frac{N_i}{n_i} \sum_{k \in S_i} y_k \quad (17)$$

con estimación de varianza dada por

$$\widehat{\text{Var}}_{MM}(\hat{t}_{y,\pi}) = \frac{N_I^2}{n_I} \left(1 - \frac{n_I}{N_I}\right) S_{\hat{t}_y S_I}^2 + \frac{N_I}{n_I} \sum_{i \in S_I} \frac{N_i^2}{n_i} \left(1 - \frac{n_i}{N_i}\right) S_{y_{S_i}}^2 \quad (18)$$

donde  $S_{\hat{t}_y S_I}^2$  y  $S_{y_{S_i}}^2$  son las varianzas muestrales de los totales y de los elementos, respectivamente.

## Práctica en R

```
UI <- levels(as.factor(Hogares$UPM))
NI <- length(UI)
nI <- 200

samI <- S.SI(NI, nI)
muestralI <- UI[samI]
```

## Práctica en R

muestraI

```
## [1] "PSU0010"  "PSU0019"  "PSU0039"  "PSU0040"  "PSU0041"
## [8] "PSU0066"  "PSU0072"  "PSU0078"  "PSU0079"  "PSU0086"
## [15] "PSU0111"  "PSU0116"  "PSU0119"  "PSU0141"  "PSU0155"
## [22] "PSU0191"  "PSU0205"  "PSU0213"  "PSU0218"  "PSU0220"
## [29] "PSU0230"  "PSU0231"  "PSU0233"  "PSU0234"  "PSU0240"
## [36] "PSU0247"  "PSU0255"  "PSU0269"  "PSU0278"  "PSU0284"
## [43] "PSU0291"  "PSU0295"  "PSU0299"  "PSU0322"  "PSU0350"
## [50] "PSU0383"  "PSU0387"  "PSU0438"  "PSU0440"  "PSU0450"
## [57] "PSU0475"  "PSU0480"  "PSU0488"  "PSU0491"  "PSU0492"
## [64] "PSU0523"  "PSU0527"  "PSU0528"  "PSU0530"  "PSU0538"
## [71] "PSU0550"  "PSU0552"  "PSU0573"  "PSU0575"  "PSU0584"
## [78] "PSU0630"  "PSU0636"  "PSU0637"  "PSU0638"  "PSU0639"
## [85] "PSU0659"  "PSU0661"  "PSU0668"  "PSU0687"  "PSU0688"
## [92] "PSU0701"  "PSU0705"  "PSU0723"  "PSU0732"  "PSU0734"
## [99] "PSU0747"  "PSU0754"  "PSU0761"  "PSU0764"  "PSU0767"
## [106] "PSU0786"  "PSU0789"  "PSU0791"  "PSU0795"  "PSU0796"
```

## Práctica en R

```
CityI <- Hogares[which(Hogares$UPM %in% muestraI),]  
head(CityI)
```

HHID	Estrato	UPM	Personas	Ingreso	Gasto	Pobreza
idHH00125	Urban	PSU0010	5	2102	1506	Relative
idHH00126	Urban	PSU0010	1	744	220	NotPoor
idHH00127	Urban	PSU0010	7	9663	4306	NotPoor
idHH00128	Urban	PSU0010	4	5107	2958	NotPoor
idHH00129	Urban	PSU0010	6	4440	4049	NotPoor
idHH00130	Urban	PSU0010	3	1615	1411	NotPoor

## Práctica en R

```
Ni <- as.vector(table(CityI$UPM))
ni <- round(Ni * 0.4)
ni

##      [1]  9 13 10 10 12 13 12 10 14 10 10 10 10 10 9 14 10 10 10
##     [26] 10 11 10 10 10 12 14 10 14 9 10 11 11 11 9 10 10 10 10
##     [51] 14 10  3  6 13 12  9 12  7  9  6 11  9  7  6  6  7  7
##     [76] 11 10  8 12 10 10  9  4 10  7  5  8  6  8  6  7  7  7
##    [101]  9  9 10 12 11  8  9 10 10 12  6  5  9  5  6  8  6  6
##   [126]  9  8 14 10 11 11 10 14 11 11 12 10 10 12 10 12 10 12  8
##   [151]  9 11  9 14 10 10 10 11 10  8 13 11  8 14 14 10  7  7
##   [176] 10 12  8  5 10 10 11 10 10 10 12 10 12 14 10 12 10 12 10

sum(ni)

## [1] 1965
```

## Práctica en R

```
sam = S.SI(Ni[1], ni[1])
conglomerado = Hogares[which(Hogares$UPM == muestra1[1]),]
muestra = conglomerado[sam,]
for (i in 2:length(Ni)) {
  sam = S.SI(Ni[i], ni[i])
  conglomerado = Hogares[which(Hogares$UPM == muestra1[i]),]
  muestra1 = conglomerado[sam,]
  muestra = rbind(muestra, muestra1)
}
```

# Práctica en R

```
rownames(muestra) <- NULL  
attach(muestra)  
dim(muestra)
```

```
## [1] 1965     7  
head(muestra)
```

HHID	Estrato	UPM	Personas	Ingreso	Gasto	Pobreza
idHH00129	Urban	PSU0010	6	4440	4049	NotPoor
idHH00131	Urban	PSU0010	2	3094	749	NotPoor
idHH00133	Urban	PSU0010	3	4950	2411	NotPoor
idHH00135	Urban	PSU0010	1	260	227	NotPoor
idHH20773	Urban	PSU0010	4	5107	2958	NotPoor
idHH20775	Urban	PSU0010	3	1615	1411	NotPoor

## Práctica en R

```
estima <- data.frame(Personas, Ingreso, Gasto)
area <- as.factor(UPM)
E.2SI(NI, nI, Ni, ni, estima, area)
```

	N	Personas	Ingreso	Gasto
Estimation	40884	144114	80755918	52423458
Standard Error	NA	NA	NA	NA
CVE	NA	NA	NA	NA
DEFF	NA	NA	NA	NA

Otros diseños en varias etapas

## Diseños en $r$ etapas

- Los principios de independencia e invarianza se siguen manteniendo en todas las etapas del diseño muestral.
- El fundamento de este diseño de muestreo es la acumulación de las estimaciones desde la última etapa hasta la primera.
- A pesar de su complejidad, los diseños con tres o más etapas son ampliamente usados en las grandes encuestas.

## Diseños en $r$ etapas sin reemplazo

El estimador de Horvitz-Thompson es

$$\hat{t}_{y,\pi} = \sum_{i \in S_I} \frac{\hat{t}_{yi}}{\pi_{li}} \quad (19)$$

con varianza estimada

$$\widehat{Var}_{BI}(\hat{t}_{y,\pi}) = \underbrace{\sum_{S_I} \sum_{Ij} \frac{\Delta_{Iij}}{\pi_{Iij}} \frac{\hat{t}_{yi}}{\pi_{li}} \frac{\hat{t}_{yj}}{\pi_{lj}}}_{\widehat{Var}(UPM)} + \underbrace{\sum_{i \in S_I} \frac{\hat{V}_i}{\pi_{li}}}_{\widehat{Var}(Resto)} \quad (20)$$

Donde  $V_i = Var(\hat{t}_{yi}|S_I)$  y  $\hat{V}_i$  es un estimador insesgado de  $V_i$  tal que  $E(\hat{V}_i|S_I) = V_i$  para todo  $i \in U_I$ .

## Diseños en $r$ etapas con reemplazo

El estimador de Hansen-Hurwitz es

$$\hat{t}_{y,p} = \frac{1}{m_I} \sum_{v=1}^{m_I} \frac{\hat{t}_{yi_v}}{p_{Ii_v}} \quad (21)$$

con varianza estimada

$$\widehat{Var}(\hat{t}_{y,p}) = \frac{1}{m_I(m_I - 1)} \sum_{v=1}^{m_I} \left( \frac{\hat{t}_{yi_v}}{p_{Ii_v}} - \hat{t}_{y,p} \right)^2 \quad (22)$$

respectivamente.

¡Gracias!

Andrés Gutiérrez

*Experto Regional en Estadísticas Sociales*

*Division de Estadísticas*

*Email: andres.GUTIERREZ@cepal.org*